

B[K, N]								2c00 3d80 3480 bc60 b400 3300 3880 bb00 ac00				b9c0 be40 3780 bc20 bcc0 3b00 bfc0 3ea0 b100				2e00 b100 b880 bd40 3b40 2800 3c00 3d80 3780			
ba00	3f60	3400		be40	ba80	3d40													
bca0	bee0	3700		3ea0	b880	3580													
b8c0	ba00	b780		3940	bb80	bda0													
								b900 3d80 3880 3100 bec0 b600 3980 3c00 3f60				b500 b700 3ea0 bc00 be20 bb40 3a80 2e00 3b40				bac0 b780 bd60 3e00 3200 bce0 b200 a800 bea0			
3300	bcc0	3a40		3600	bb80	3cc0													
3f60	3d20	3840		3a40	be00	b700													
bce0	bc80	3840		be20	be80	3ee0													

A[M, K]				C[M, N] += A[i, k] @ B[k, j]				k = 0 of 2											
c000	bd0c	3ca0		b840	b840	be40		4292	b604	c266		4290	452f	c7d4		3d17	c4cd	c3dc	
3cc0	3100	3980		ba80	b500	2800		c08b	3fbd	b9ee		bef8	b824	b020		3a2a	36f0	2980	
b580	3480	3dc0		2800	3700	b600		3598	bd00	b8a2		41c0	bd36	c25a		3454	c1be	bbb4	
3400	3880	b8c0		bf80	b200	bf80		3c2d	4409	bfe5		4059	4520	c403		bc52	c2d4	c436	
bce0	3c60	3940		3de0	bee0	bc80		c06f	c74d	b7f4		4514	4194	be56		c1ba	3d16	b9fc	
3a00	bf40	bb80		3000	b840	ba40		402e	4540	ba20		c3ec	427a	39be		3a6e	412f	bd31	
b600	3900	3fa0		3f40	3b00	be00		4088	c114	35ec		4688	c0d1	c389		bea6	c1a6	c053	
3900	bec0	b880		b200	b840	3780		3330	42fb	b7f8		c558	3cb8	3f63		3fb3	41c3	3a66	
3d20	3200	bac0		bd60	b900	bcc0		b968	44ce	bcdc		bdad	438b	b6e4		b964	3790	c084	
bea0	bda0	bc20		ba40	b500	3d80		3c3b	bb10	b8bc		c21f	4024	35d8		407b	b240	3e04	
bfc0	3cc0	3840		3dc0	3100	3500		a300	c7df	3ca2		4587	beba	b9a6		bf1f	bd9a	3c08	
3840	39c0	3da0		38c0	b980	bec0		bc95	bbfc	bc0a		431b	3c40	c1db		be67	b640	c09a	
3fc0	3000	b200		3300	3400	3800		be6e	4237	3c7e		c2ef	c18c	437f		afc0	4198	38ac	
bfa0	b200	b500		ac00	bd40	3e60		c0ff	c679	b53c		bb6e	3dbe	3c1f		ae00	c0c6	b89a	
3100	bf20	bd0c		b800	b580	bc20		429f	45be	bcc0		c208	44e2	b8d0		3c99	3fac	b418	
bc60	2e00	3580		3700	bee0	3ea0		0000	0000	0000		0000	0000	0000		0000	0000	0000	
bfe0	3580	3400		3fa0	bd00	3c00		0000	0000	0000		0000	0000	0000		0000	0000	0000	
bfc0	b600	3fa0		b700	b680	3800		0000	0000	0000		0000	0000	0000		0000	0000	0000	
bb00	0000	bb80		2e00	bf20	3e40		0000	0000	0000		0000	0000	0000		0000	0000	0000	
ac00	bf80	3c20		3780	3200	39c0		0000	0000	0000		0000	0000	0000		0000	0000	0000	
be20	2c00	bbc0		be00	b480	3d80		0000	0000	0000		0000	0000	0000		0000	0000	0000	
3fa0	3e00	3f40		bde0	3d40	3b40		0000	0000	0000		0000	0000	0000		0000	0000	0000	
3f00	b200	39c0		38c0	3fc0	3c20		0000	0000	0000		0000	0000	0000		0000	0000	0000	
bd00	bc60	bf60		3e60	bfc0	bb00		0000	0000	0000		0000	0000	0000		0000	0000	0000	
bc40	bb00	b580		2c00	bfc0	3680		0000	0000	0000		0000	0000	0000		0000	0000	0000	
3200	3d00	3200		ba40	bf80	3fa0		0000	0000	0000		0000	0000	0000		0000	0000	0000	
3d60	3ce0	b940		be60	3dc0	3d00		0000	0000	0000		0000	0000	0000		0000	0000	0000	

```
acc += tl.dot(a_tile, b_tile) # fp16 in, fp32 accumulate; C tiles above are the real A @ B
```

Kernel Engineering

From silicon to speculative decoding – GPU kernels for modern LLMs.